

Otimização de Redes Neurais Quânticas (QNNs/VQAs) via Estruturas em Árvore e Meta-heurísticas

Disciplina: Aplicações de Machine Learning

Aluna: Laíse Magalhães

Índice

- Fundamentos (Objetivos e Qubits)
- Circuitos, Portas e Medição
- O Classificador Quântico Variacional (CQV)
- Laboratório Aberto
- Otimização por Árvores e Meta-heurísticas
- Resultados e Conclusão

ETAPA 1

Qubits, Circuitos e Portas quânticas


| Qubits

Enquanto um bit clássico só pode assumir os valores absolutos 0 ou 1, os qubits podem existir em superposição — uma combinação linear de ambos os estados simultaneamente — Representados no espaço de Hilbert através da notação de Dirac, os qubits podem explorar qualquer ponto contínuo na superfície da Esfera de Bloch antes de serem medidos.

● 0



● 1

Bit Classico




Qubit


| Portas Quânticas

Gate	Notation	Matrix
NOT (Pauli- X)		$\begin{bmatrix} 0 & 1 \\ 1 & 0 \end{bmatrix}$
Pauli- Z		$\begin{bmatrix} 1 & 0 \\ 0 & -1 \end{bmatrix}$
Hadamard		$\frac{1}{\sqrt{2}} \begin{bmatrix} 1 & 1 \\ 1 & -1 \end{bmatrix}$
CNOT (Controlled NOT)		$\begin{bmatrix} 1 & 0 & 0 & 0 \\ 0 & 1 & 0 & 0 \\ 0 & 0 & 0 & 1 \\ 0 & 0 & 1 & 0 \end{bmatrix}$

| Circuito Clássico e Quântico




Portas lógicas deterministas (AND, OR, NOT) com caminhos estáticos.




Portas de rotação com ângulos ajustáveis e emaranhamento.


| Circuito Quântico Variacional (VQC)



| Circuito Quântico Variacional (VQC)



| Ansatz



ETAPA 2

Artigo: Adaptive quantum ansatz circuit design and optimization



Adaptive quantum ansatz circuit design and optimization

Xueyun Cheng¹ · Fan Yang¹ · Rong Diao¹ · Fei Ding¹ · Shuxian Zhao³ · Zhijin Guan^{1,2}

Received: 9 December 2025 / Accepted: 30 July 2026

© The Author(s), under exclusive licence to Springer Nature Switzerland AG 2026


Abstract

To address the challenges of poor adaptability in variational quantum algorithm ansatz templates and high noise sensitivity in deep structures on NISQ devices, an adaptive ansatz construction and optimization method is proposed. This approach dynamically adjusts circuit structures and optimizes performance according to varying datasets and task requirements. A full binary tree is used to represent the predefined ansatz structure, and a simulated annealing algorithm guides the qubit merging path to facilitate construction. By integrating hierarchical ansatz training with multi-objective particle swarm optimization, the method simultaneously optimizes expressibility, entanglement capability, and circuit depth. This ensures circuit depth compression while balancing these performance metrics, enabling task-oriented ansatz design and circuit optimization. On three binary classification tasks from the Iris dataset, the method achieved average accuracies of 98.3%, 96.7%, and 96.7% under 8-qubit conditions, outperforming random qubit selection. For three-class classification tasks on MNIST and CIFAR-10, average accuracy improved by 5.5% and 1.4%, respectively, under 12-qubit conditions. Furthermore, multi-objective particle swarm optimization reduced circuit depth by approximately 18.5% under 12-qubit conditions.

Keywords Variational Quantum Algorithms · Ansatz Design · Full Binary Tree · Simulated Annealing · Multi-Objective Particle Swarm Optimization

| Arquitetura Base

$U(x)$: Responsável por traduzir os dados clássicos (como as características das flores Iris ou pixels de imagens) em estados quânticos utilizando portas de rotação R_y .



$V(\theta)$: O circuito parametrizado com rotações R_z e portas de emaranhamento CNOT, que funciona como o modelo treinável.

Fig. 1 Schematic of the parameterized quantum circuit (PQC) structure

| Problemas dos Modelos Fixos


Falta de adaptabilidade às tarefas específicas: Tarefas com estruturas complexas ou níveis de ruído variados exigem arquiteturas sob medida, algo que um template fixo não consegue fornecer.

Conflito rígido entre métricas de desempenho: Não há flexibilidade para equilibrar trade-offs de forma dinâmica conforme a exigência do problema.

Acumulação de ruído e degradação (Barren Plateaus): Para tentar contornar a baixa expressividade de um template fixo, os pesquisadores frequentemente recorrem ao empilhamento cego de várias camadas profundas (hardware-efficient ansatzes). No entanto, em dispositivos quânticos ruidosos (NISQ), o aumento descontrolado da profundidade acumula erros de hardware drasticamente e cai no problema do gradiente evanescente (barren plateaus), **estagnando o aprendizado.**

| Abordagem Hierárquica

Para resolver isso, o artigo propõe uma **construção hierárquica baseada numa árvore binária completa**. Em vez de ligar tudo de qualquer maneira, dividimos os dados em partições locais e fazemos um processo de fusão de baixo para cima (*bottom-up*), unindo os qubits de forma inteligente.



O **Simulated Annealing** modela a seleção de qubits como um problema de otimização combinatória, guiando o caminho de união para preservar a informação mais importante para a classificação.

Fig. 5 Correspondence between circuit partitions and the full binary tree

| Abordagem Hierárquica






Fig. 6 Qubit organization and merging based on a full binary tree

| Estratégia de Seleção Adaptativa (HAC-SA)



(a)

Fig. 12 Illustration of the HAC-SA algorithm workflow on the Iris dataset (binary classification of class 0 vs. 1). **(a)** The process of adaptive qubit selection and merging at a node using simulated annealing. **(b)** The resulting hierarchical quantum circuit structure after applying the transformation rules



(b)

| Otimização Global (MOPSO)




Fig. 14 Ansatz Sub-circuit with minimum circuit depth selected via MOPSO

O algoritmo atua como um enxame de partículas multiobjetivo que equilibra simultaneamente quatro metas concorrentes:

- Maximizar a **expressibilidade**;
- Maximizar a **capacidade de emaranhamento**;
- Minimizar a **profundidade do circuito** para poupar hardware;
- Garantir uma restrição rigorosa de **acurácia mínima** baseada no baseline anterior.

ETAPA 3

Análise de Resultados

| Comparação de resultados


Treino do modelo básico

Iteração	Básico	10		Acurácia:	60.8%
Iteração	Básico	20		Acurácia:	61.7%
Iteração	Básico	30		Acurácia:	61.7%
Iteração	Básico	40		Acurácia:	63.3%
Iteração	Básico	50		Acurácia:	63.3%
Iteração	Básico	60		Acurácia:	62.5%
Iteração	Básico	70		Acurácia:	63.3%
Iteração	Básico	80		Acurácia:	63.3%
Iteração	Básico	90		Acurácia:	63.3%
Iteração	Básico	100		Acurácia:	63.3%
Iteração	Básico	110		Acurácia:	63.3%
Iteração	Básico	120		Acurácia:	63.3%
Iteração	Básico	130		Acurácia:	63.3%
Iteração	Básico	140		Acurácia:	63.3%
Iteração	Básico	150		Acurácia:	63.3%

Treino do modelo adaptativo

Iteração	Avançado	10		Acurácia:	66.7%
Iteração	Avançado	20		Acurácia:	66.7%
Iteração	Avançado	30		Acurácia:	78.3%
Iteração	Avançado	40		Acurácia:	74.2%
Iteração	Avançado	50		Acurácia:	73.3%
Iteração	Avançado	60		Acurácia:	69.2%
Iteração	Avançado	70		Acurácia:	70.0%
Iteração	Avançado	80		Acurácia:	71.7%
Iteração	Avançado	90		Acurácia:	70.8%
Iteração	Avançado	100		Acurácia:	70.8%
Iteração	Avançado	110		Acurácia:	70.0%
Iteração	Avançado	120		Acurácia:	70.8%
Iteração	Avançado	130		Acurácia:	70.8%
Iteração	Avançado	140		Acurácia:	70.8%
Iteração	Avançado	150		Acurácia:	70.8%

| Comparação de resultados



| Comparação de resultados




Fig. 15 Comparison of training loss between HAC-SA and Random AC on the Iris dataset. The curves depict the loss progression over 25 training epochs for the three binary classification tasks, demonstrat-

ing the convergence behavior of the proposed qubit selection strategy against the random baseline

| Conclusões do artigo

Desempenho Geral em Tarefas Complexas: O método adaptativo (HAC-SA) provou ser altamente competitivo e superou abordagens tradicionais (como TR-QNet e VQTN) em várias tarefas de classificação binária e ternária em datasets desafiantes como o MNIST e o CIFAR-10.

Impacto da Compressão na Profundidade do Circuito: Através da otimização multiobjetivo do MOPSO, o artigo demonstra uma **redução expressiva na profundidade do circuito de aproximadamente 18,5%** sob condições de 12 qubits.

O Equilíbrio entre Expressibilidade e Emaranhamento: Os testes do artigo revelam que, ao modular o número de camadas, quando a profundidade do circuito cresce, a expressibilidade satura ligeiramente enquanto a capacidade de emaranhamento se fortalece de forma contínua.

Robustez e Estabilidade: Os testes de sensibilidade com diferentes temperaturas iniciais no *Simulated Annealing* provaram que o algoritmo apresenta flutuações mínimas, demonstrando uma robustez estatística excelente e pouca sensibilidade a variações estocásticas.

ETAPA 4

Laboratório Aberto

| Laboratório Aberto

1. Os Dados e o *Embedding*

- Dataset Iris – Classificar espécies de flores usando características numéricas (comprimento e largura de pétalas/sépalas).
- Computadores quânticos lidam com amplitudes de estados probabilísticos, não com números tabulares tradicionais.
- **(Angle Embedding / Amplitude Embedding)**: Técnica que transforma os dados clássicos (x) em ângulos ou estados quânticos para alimentar os qubits.

2. Código

- **Carregamento & Pré-processamento**: Limpeza dos dados e seleção das features relevantes.
- **Definição do Dispositivo (Device)**: O simulador quântico.
- **O Circuito / Ansatz**: A função que aplica as portas de rotação e o emaranhamento.
- **O Otimizador e o Treino**: O laço de repetição que calcula a perda e ajusta os pesos iterativamente.

FIM

Obrigado!

